SOLARCHECK AI · FICHA TÉCNICA

Proyecto grupal · IA Generativa para la Gestión Industrial · UDD, 2026

1. Problema y objetivo

Clasificar visualmente seis condiciones de paneles solares como apoyo educativo a la priorización de inspecciones. No es un sistema de certificación de seguridad ni sustituye a personal técnico.

2. Origen del dataset

Dataset: Solar Panel Images - Clean and Faulty Images, Kaggle, publicado bajo el usuario pythonafroz. Enlace: https://www.kaggle.com/datasets/pythonafroz/solar-panel-images. Descarga mediante kagglehub. No se documentó cómo se capturaron originalmente las fotografías. Licencia no especificada en el material de entrenamiento: verificar antes de redistribuir imágenes.

3. Clases y particiones

Clase	Train	Validación	Test	Total
Bird-drop	134	28	29	191
Clean	135	29	29	193
Dusty	133	28	29	190
Electrical-damage	72	16	15	103
Physical-Damage	48	11	10	69
Snow-Covered	86	18	19	123
TOTAL	608	130	131	869

La clase New (16 imágenes) se excluyó. Las 869 fotografías restantes se dividieron mediante partición estratificada, aproximadamente 70/15/15 y random_state=42. Hay desbalance entre 69 y 193 ejemplos por clase; se usó una función de pérdida ponderada.

4. Modelos y validación

Línea base: CLIP zero-shot (Hugging Face), con descripciones textuales. Modelo principal: EfficientNet-B0 (timm) preentrenado en ImageNet, ajustado con una salida de seis clases, data augmentation solo en entrenamiento, AdamW y selección de la mejor época por balanced accuracy de validación. Se emplea normalización ImageNet y resolución 224 × 224.

EVALUACIÓN Y USO RESPONSABLE

5. Evaluación de la exportación reciente · 19/10/2026

Los resultados siguientes provienen exactamente del archivo modelo/clases.json dentro de solarcheck.zip enviado por el grupo. Estos metadatos acompañan a los pesos usados por la aplicación.

Métrica de prueba	EfficientNet-B0 · nueva exportación
Accuracy	87,8 %
Balanced accuracy	87,8 %

La última exportación no adjunta una nueva matriz de confusión ni reportes de recall por clase. Para documentarlos, guarda en Colab el notebook ejecutado de esta misma sesión; no uses la matriz anterior como si proviniera de estos pesos.

6. Resultados históricos · ejecución anterior

Métrica	CLIP zero-shot	EfficientNet-B0
Accuracy	48,1 %	74,0 %
Balanced accuracy	51,4 %	76,8 %
Recall Dusty	3,4 %	48,3 %

En el notebook original, el modelo anterior clasificó como Clean 5 de 29 fotografías Dusty. Esta cifra describe la ejecución anterior, NO los pesos de la exportación reciente. Ambas ejecuciones deben mantenerse diferenciadas.

7. Consecuencias y limitaciones

La omisión de daños físicos o eléctricos podría retrasar una inspección especializada. El modelo utiliza una sola fuente de datos, con clases desbalanceadas (solo 10 ejemplos de daño físico en el test original); no está validado en instalaciones reales ni con diversidad completa de condiciones. Las probabilidades softmax no son garantías ni evaluación de riesgo calibrada.

8. Aplicación y estado

Streamlit carga fotografías, devuelve clase y seis probabilidades, y permite solicitar a Gemini una recomendación educativa enviando solo texto, no la imagen. Los pesos entrenados ya están incorporados. Para entregar la app publicada, falta configurar la clave privada de Gemini, desplegar en Streamlit Cloud, probar la clasificación y el enlace público, y actualizar las salidas del notebook reciente.