IA GENERATIVA · VISIÓN ARTIFICIAL

SolarCheck AI

Clasificación visual de paneles solares y recomendaciones preventivas con IA

CLIP zero-shot vs. EfficientNet-B0 • Streamlit + Gemini

PROYECTO GRUPAL · UDD · 2026

¿Qué problema queremos resolver?

Del panel en una fotografía a una decisión preventiva informada.

Revisión visual

Identificar suciedad y señales evidentes de deterioro puede requerir tiempo y experiencia.

Clasificación automática

El modelo organiza las imágenes en seis condiciones posibles y muestra incertidumbre.

Apoyo a decisiones

Gemini transforma la salida técnica en una recomendación educativa, nunca una orden de reparación.

Objetivo: priorizar inspecciones, no sustituir a profesionales ni certificar seguridad.

869 imágenes · 6 clases

Dataset de Kaggle, procedencia indicada: Afroz (pythonafroz). Excluimos “New” (16 fotografías).

Limpio	193
Aves	191
Polvo	190
Nieve	123
Daño eléctrico	103
Daño físico	69

Train	608
Validación	130
Test	131

Estratificado 70/15/15 aprox. · Desbalance 69–193 por clase · Licencia no especificada

Dos enfoques, mismo conjunto de prueba

El modelo principal reutiliza conocimiento aprendido previamente (transfer learning).

CLIP · línea base

- ViT-B/32 de Hugging Face
- Zero-shot: sin ajuste con estas imágenes
- Compara foto con seis descripciones en inglés

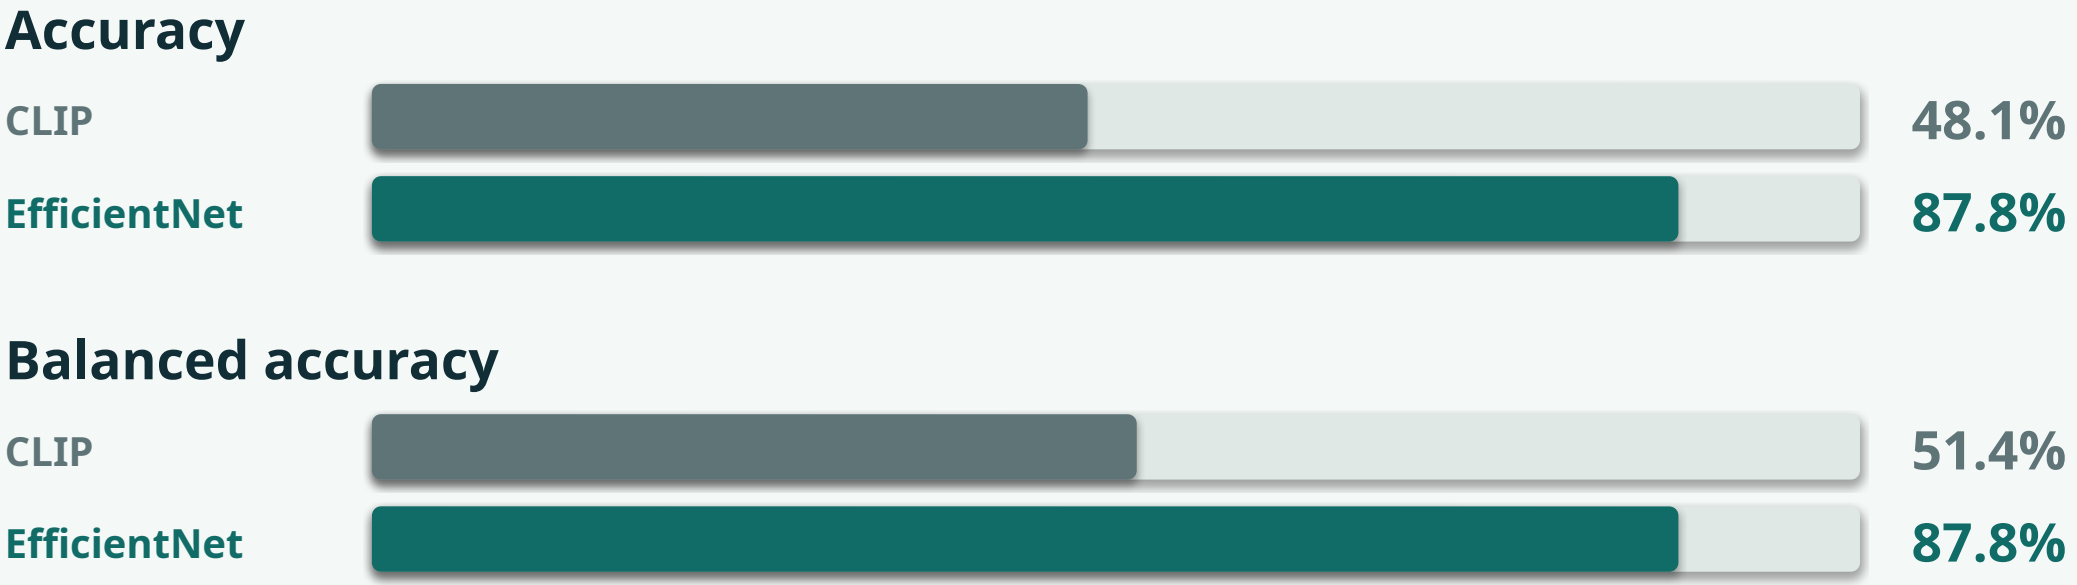
EfficientNet-B0 · elegido

- Modelo timm preentrenado en ImageNet
- Nueva salida de 6 clases
- 15 épocas + class weights + augmentation
- Mejor época elegida con validación

Prueba final: 131 imágenes reservadas · Accuracy, balanced accuracy, recall y matrices de confusión.

EfficientNet-B0 supera a CLIP

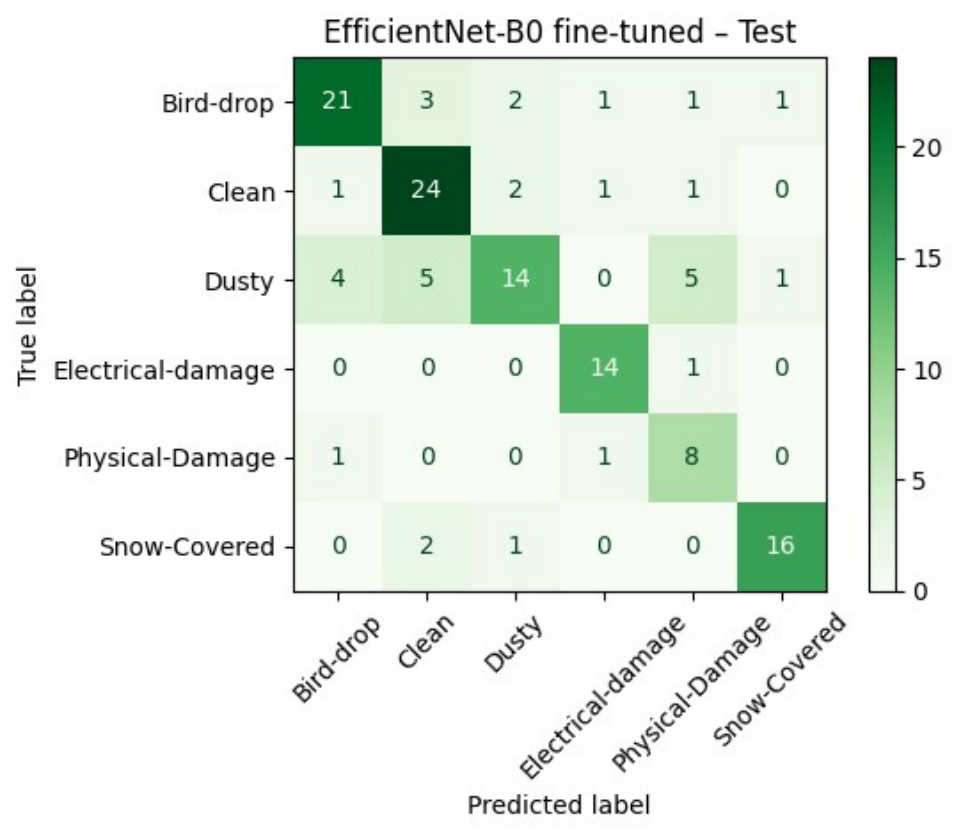
CLIP: sesión anterior. EfficientNet: exportación reciente de Colab.



Exportación actual 87,8% · CLIP anterior 48,1% (distintas ejecuciones)

Matriz histórica: ejecución anterior

Matriz y recalls de la ejecución anterior (accuracy 74,0%); no son de los pesos actuales.



Polvo · ejecución previa

5 / 29

En la sesión anterior: Dusty confundido con Clean.

Recall Dusty anterior: 48,3%

Mayor riesgo potencial: omitir un daño eléctrico y retrasar la inspección técnica.

Prototipo educativo: revisión humana obligatoria.

De la imagen a la recomendación

Stack: Python · Streamlit · timm / PyTorch · Google Gemini.

01

Subir fotografía

JPG o PNG

02

Clasificación

6 probabilidades

03

Resultado

Clase + confianza

04

Gemini

Consejo cauteloso

La foto NO se envía a Gemini. La clave está en Secrets, fuera de GitHub.

Pesos reales incorporados; falta configurar Gemini y probar la app publicada.

Código organizado para poder explicar cada parte

Separamos entrenamiento, predicción, aplicación y despliegue.

01 · Colab

Descarga datos, crea splits, compara CLIP y EfficientNet, evalúa en test y exporta el `.pt`.

02 · Inferencia

Carga pesos entrenados, normaliza imagen a 224×224 y calcula softmax de seis salidas.

03 · App + LLM

Streamlit muestra resultados; Gemini recibe texto con política de seguridad y revisión humana.

GitHub → Streamlit Community Cloud | Pesos reales + GEMINI_API_KEY (Secrets)

Avances, limitaciones y siguiente paso

Lo importante es que el modelo sea evaluable, útil y responsable.

Logros medidos

- Seis clases con datos estratificados
- Dos métodos evaluados sobre el mismo test
- 87,8% reportado en última exportación
- Código e interfaz listos para publicar

Pendientes reales

- Guardar salidas del notebook de nueva ejecución
- Configurar y verificar clave privada de Gemini
- Probar y publicar enlace público
- Ampliar datos, calibrar y validar en terreno

IA como apoyo a decisiones; nunca como reemplazo de la seguridad técnica.